

题目

摘要

随着 3D 传感器的普及,点云数据在多个领域的应用日益增多,但点云数据的高维、稀疏性和不规则性给异常检测带来了挑战。研究趋势集中在数据合成方法、高精度 3D 点云数据集的开发,以及有效的点云特征提取方法。当前的 3D 异常检测方法主要分为基于特征嵌入的方法和基于重建的方法,其中记忆库方法和 MAE 机制的重建模型是主流技术。Real3D-AD 数据集以其高分辨率和高精度的点云数据,有效避免了盲点问题,提供了全面的缺陷检测。Reg3D 方法通过双记忆库的方式,结合点级和全局特征,提高了异常检测的准确性。此外,文章还讨论了频域特征抽取、特征插值和异常分数计算的个性化模块,旨在提升点云异常检测的性能和可靠性。

关键词: 3D 异常检测; 数据集; Real3D

1 引言

随着计算机视觉和传感器技术的发展,3D 点云数据在自动驾驶、机器人导航、安防监控和工业检测等多个领域扮演着越来越重要的角色。然而,如何从这些复杂的 3D 数据中准确识别出异常或异常区域,成为了一个亟待解决的问题。尤其是在工业生产领域,高精度的点云异常检测对于产品质量控制和生产线的自动化至关重要。

当前的主流 3D 数据集 MVTEC3D-AD,由于其精度和点云密度的限制,并不足以满足高精度点云异常检测的需求。MVTEC3D-AD 为每个对象仅提供有限的 4,147 个点,点精度为 0.11 毫米,这种精度在工业应用中显得不足。此外,采用 RGBD 相机(如 MVTEC 3D 和 Eyescannies)收集的 3D 数据存在盲点问题,这限制了 3D 异常检测数据集的全面性和准确性。

为了解决这一问题,Real3D-AD 数据集 [4] 应运而生。Real3D-AD 为每个对象提供的点云中点的数量估计约为 13 万个,是 MVTEC3D-AD 的大约 100 倍。此外,Real3D-AD 的点精度高达 0.010 毫米,比 MVTEC3D-AD 高出十倍。这种高分辨率和高精度的点云数据,使得 Real3D-AD 能够有效避免盲点问题,提供更为全面和详细的产品缺陷检测。

同时论文提出一个新的异常检测方法 Reg3D,提出了基于记忆库的异常检测方法。Reg3D 的主要创新在于提出了双记忆库的方式,使用两种特征分别代表全局特征与局部特征进行记忆库方式的异常检测。这种方法利用双特征表示方法来保留训练原型的局部和全局特征,提供了更为全面的异常检测能力。

2 相关工作

由于 3D 异常检测存在数据标注困难，异常定义多样的特点 [7]，因此大多数的 3D 异常检测方法是自监督或者无监督。在当前的 3D 异常检测的研究中主要有两个方法，一种是基于特征嵌入的方法依赖于点云的特征表示通过对正常点云特征的学习和比较来检测异常。另一种是基于重建的方法使用如自编码器、生成对抗网络、变换器和扩散模型的方法尝试重建点云 [9]，通过分析重构误差来识别异常。

基于特征嵌入的方法

目前基于特征嵌入的方法中大部分都使用的是记忆库 (memory bank) [1] 的方法。记忆库方法是一种无监督的方法 [1] 主要流程如下图 1：




图 1. 记忆库方法的流程

1. 首先选择效果好的特征提取方法对训练数据进行特征提取，获得正常数据的特征编码并保存在记忆库中 [10]。
2. 然后对测试数据也进行特征提取获取测试数据的特征编码，通过计算测试数据的特征编码与记忆库中训练数据的正常特征编码的差异判断测试数据是否异常以及异常的位置。

基于重建的方法

基于重建的方法中，目前主流的方法是使用 MAE (Masked Autoencoder) [5] 机制的重建模型。MAE 机制的重建模型的主要流程如图 1.2：




图 2. MAE 机制重建流程

1. 首先对输入点云进行随机掩盖，将一部分点云数据进行掩盖处理。
2. 然后将输入点云送入自编码器的编码器部分，获取中间表征。
3. 最后将中间表示被送入自编码器的解码器部分，重建输入点云。

3 本文方法

在异常检测方法上，Reg3D 提出了基于记忆库的异常检测方法。Reg3D 的主要创新在于提出了双记忆库的方式，使用两种特征分别代表全局特征与局部特征进行记忆库方式的异常检测。这种方法利用双特征表示方法来保留训练原型的局部和全局特征，提供了更为全面的异常检测能力。

PointMAE 特征在异常检测中也起到了重要作用。PointMAE 特征代表全局特征，而坐标值则封装了各个点的定位属性，即点级特征。PointMAE 模型优先考虑获得训练原型的全面表示，这在训练阶段旨在建立一个邻域敏感特征存储库，这些特征来自所有旨在用作内存库的常规原型。




图 3. Reg3D-AD 流程

如图 3 为 Reg3D-AD 方法的 Pipeline 在 Reg3D-AD 方法中，异常分数的计算是通过结合点级特征和全局特征来实现的。在训练阶段，系统会从训练集中提取这两种特征，并将它们存储在内存库中。点级特征主要关注每个点云中点的坐标值，即 x 、 y 和 z 的值，而全局特征则通过 PointMAE 特征来表示，这种特征能够捕捉到点云的整体结构信息。

在推理阶段，系统会对测试样本进行校准，并提取其点级特征和全局特征。对于测试 3D 对象的每个点级特征，系统会在内存库中找到其最近邻，并计算得分。这个过程涉及到最近邻搜索算法，通常需要遍历内存库中的所有特征，尤其是在特征库很大的时候，计算代价可能较大。

全局特征的计算方法与点级特征类似。系统会计算测试特征与内存库之间的距离，然后根据这个距离来计算每个点的异常分数。异常分数是一个指标，用于衡量数据点与正常数据点之间的差异程度。得分越高，表示越异常。在异常检测中，通常将得分高于某个阈值的数据点视为异常点。

这种结合点级和全局特征的方法能够提供更全面的异常检测能力，因为它不仅考虑了单个点的位置信息，还考虑了点云的整体结构信息。通过这种方式，Reg3D-AD 方法能够有效地识别出点云中的异常区域，并准确地定位异常发生的确切位置，这对于后续的缺陷分析和修复至关重要。

但是通过实验，当前 PointMAE 特征存在一定的缺陷，无法完全描述点云的全局特征，因此需要另一种描述点云的特征描述符。通过了解，频域特征能够很好的描述点云特征，由于频域具有区分高频信息与低频信息的能力，通常异常为高频信息，因此能够提取点云的高频信息，从中获取异常点。

同时由于对于大型点云，对每一个点进行特征提取需要大量的计算资源并不现实，因此使用特征插值的方式，对部分点计算特征，对剩余部分使用特征插值的方式获取特征。

4 复现细节

复现部分代码主要借鉴了 Real3D 论文提供的代码，并加上一些创新更改频域特征为全局特征，并使用特征插值的方法为每个点获取特征：

频域特征抽取

在频域中，高频信息通常代表异常信息 [2]，因此可以通过频域的这个特点将 3D 点云转换到频域中，然后对点云的频域形式进行特征抽取这样能够更好地获取到异常的特征，从而更好的进行异常检测。而对于如何将点云转换到频域通过资料了解到两种方法，一种为先将点云转换为图边的权重由点与点之间距离通过公式确定，然后使用图傅里叶变换，将其转换到频域。另一种方法为对点云的 xyz 三个维度分别使用离散傅里叶变换获取点在 3 个维度上的频域信息。这两种方法各有优缺点，第一种方法构建为图能够完整的保存点云信息效果应该比第二种方法单独各个维度转换效果要好，但是由于图以及转换为频域计算拉普拉斯矩阵的限制，如果点云中点的数量过多容易导致内存不足等问题。当前主流的 Real3D 数据集中一个点云包含 10w 左右个点，如果构建为图将导致内存不足以及计算量过大等问题，如果采用降采样方法减少点云中点的数量需要减少到 2000 个点左右才能够满足要求但是由于点的数量减少过多会导致在降采样中被消除的问题，因此使用图傅里叶变换的方法只能对点数量较少的点云数据使用。而第二种方法则没有内存和计算的限制，但是由于是三个维度分别计算容易导致信息缺失。[3] 当前的方法在特征提取方面与主流技术存在差距，这可能是由于直接从频域中提取信息，而没有利用深度学习模型的能力来学习更深层次的特征表示，因此后续可以训练一个模型用于提取频域信息中的特征。

特征插值

点云数据通常包含海量的点，对于每个点逐一使用特征提取器进行特征提取在计算资源和时间成本上都难以接受 [6]。因此，常用的处理方法是对点云进行下采样，选择部分点来进行特征提取。然而，这种方法也存在一定的问题：由于只对部分点进行了特征提取，剩余未提取特征的点在后续计算异常分数时会因为缺乏特征信息而导致异常分数的不准确。[8] 为了解决这一问题，可以引入特征插值的方法。具体来说，通过对已经完成特征提取的点进行特征插值，为没有经过特征提取的点计算特征。这种方法能够充分利用已有的特征信息，基于点云的空间分布规律或几何结构，估计未提取点的特征。通过这种方式，可以确保每个点都拥有特征，从而在计算异常分数时能够更加准确地反映整个点云的实际情况。特征插值的方法有多种可选实现，常见的包括基于距离加权插值（如反距离权重法）、基于三角网格的插值（如 Delaunay 三角剖分）、以及基于空间平滑的插值（如高斯核平滑）。选择具体插值方法时，需要结合点云的分布特性、特征的复杂度以及插值的计算成本进行综合考虑。通过引入特征插值，不仅可以弥补下采样方法的局限性，还能在更大程度上提升点云异常检测的准确性和可靠性。

4.1 实验环境搭建及使用

实验在 CUDA 11.3 下实施，具体的库可以查阅项目中的 real3dad.yaml 文件，可以查阅 readme.md 文件获取运行代码的方法。

5 实验结果分析

下图 4 为使用第二种频域特征提取的方法使用 Real3D 数据集的实验结果：

Task	Image AUC	Pixel AUC	Image AP	Pixel AP	Time Cost (s)
Airplane	0.7932	0.5733	0.8275	0.0368	2.651
Car	0.6964	0.5871	0.7100	0.0352	1.049
Candybar	0.5880	0.5305	0.6174	0.0432	0.685
Chicken	0.6040	0.5049	0.6200	0.0353	2.134
Diamond	0.5468	0.5184	0.5828	0.0443	0.775
Duck	0.6228	0.6431	0.6068	0.0414	2.452
Fish	0.4884	0.6669	0.5636	0.0795	0.673
Gemstone	0.4760	0.5079	0.4667	0.0186	0.748
Seahorse	0.5860	0.5841	0.6355	0.0517	0.531
Shell	0.4694	0.6571	0.4933	0.0551	0.978
Starfish	0.6092	0.5889	0.5968	0.0542	0.599
Toffees	0.6516	0.6699	0.6099	0.0540	1.020
Summary	0.5943	0.5860	0.6109	0.0458	1.1914

图 4. 频域特征实验数据

当前的方法在特征提取方面与主流技术存在差距，这可能是因为直接从频域中提取信息，而没有利用深度学习模型的能力来学习更深层次的特征表示，因此后续可以训练一个模型用于提取频域信息中的特征。

如图 5 为使用 pointmae 特征提取器和位置信息进行异常分数计算的实验数据：

Task	Image AUC	Pixel AUC	Image AP	Pixel AP	Time Cost (s)
Airplane	0.6388	0.7006	0.6127	0.0260	10.0133
Car	0.8028	0.7663	0.7656	0.3771	6.8732
Candybar	0.9004	0.7741	0.9070	0.2668	6.2273
Chicken	0.7792	0.7961	0.8327	0.2870	10.0751
Diamond	0.6708	0.6829	0.6293	0.0472	6.0203
Duck	0.7828	0.6987	0.6835	0.0250	8.7620
Fish	0.9332	0.8327	0.9488	0.4382	6.2220
Gemstone	0.5336	0.5860	0.4955	0.0091	6.4957
Seahorse	0.5208	0.8577	0.5439	0.3474	5.7338
Shell	0.5725	0.8510	0.5699	0.1117	38.1081
Starfish	0.5072	0.6752	0.5011	0.0495	41.0427
Toffees	0.8888	0.7836	0.9149	0.3312	7.3090
Summary	0.7109	0.7504	0.7004	0.193	12.7402

图 5. 加入位置信息的异常分数计算实验数据

从实验结果来看，引入点云的位置信息显著提升了异常检测的效果。这一改进弥补了仅依赖特征距离方法的不足，使得检测结果更加精准。

6 总结与展望

Reg3D 方法的提出通过双记忆库的方式结合点级和全局特征，显著提高了异常检测的准确性。在特征提取与插值方面，我们探讨了两种方法的优缺点，并提出了利用深度学习模型

来提取更深层次特征的可能性。同时，特征插值方法的引入，有效解决了下采样带来的特征信息缺失问题。通过结合点的空间位置信息，我们改进了异常分数的计算方法，使得异常检测结果更加精准。

尽管本研究在 3D 点云异常检测领域取得了一定的进展，但仍存在一些挑战和未来的研究方向。未来的研究可以进一步探索和优化深度学习模型，以自动学习频域中的特征表示，提高异常检测的准确性和鲁棒性。考虑到多模态数据的互补性，未来的研究可以探索如何有效地融合点云数据与其他类型的传感器数据，以实现更全面的异常检测。

参考文献

- [1] Yunkang Cao, Xiaohao Xu, and Weiming Shen. Complementary pseudo multimodal feature for point cloud anomaly detection. *Pattern Recognition*, 156:110761, 2024.
- [2] D Liang, T Feng, X Zhou, et al. Parameter-efficient fine-tuning in spectral domain for point cloud learning. *arXiv preprint arXiv:2410.08114*, 2024.
- [3] Dingkan Liang, Xin Zhou, Wei Xu, Xingkui Zhu, Zhikang Zou, Xiaoqing Ye, Xiao Tan, and Xiang Bai. Pointmamba: A simple state space model for point cloud analysis. *arXiv preprint arXiv:2402.10739*, 2024.
- [4] J Liu, G Xie, R Chen, et al. Real3d-ad: A dataset of point cloud anomaly detection. In *Advances in Neural Information Processing Systems*, volume 36, 2024.
- [5] Y Pang, W Wang, F E H Tay, et al. Masked autoencoders for point cloud self-supervised learning. In *European Conference on Computer Vision*, pages 604–621. Springer Nature Switzerland, 2022.
- [6] C Wang, H Zhu, J Peng, et al. M3dm-nr: Rgb-3d noisy-resistant industrial anomaly detection via multimodal denoising. *arXiv preprint arXiv:2406.02263*, 2024.
- [7] X Zhang, S Zhang, and J Yan. Pcp-mae: Learning to predict centers for point masked autoencoders. In *NeurIPS 2024 Proceedings*. NeurIPS, 2024.
- [8] Baozhu Zhao, Qiwei Xiong, Xiaohan Zhang, Jingfeng Guo, Qi Liu, Xiaofen Xing, and Xiangmin Xu. Pointcore: Efficient unsupervised point cloud anomaly detector using local-global features. *arXiv preprint arXiv:2403.01804*, 2024.
- [9] Qihang Zhou, Jiangtao Yan, Shibo He, Wenchao Meng, and Jiming Chen. Pointad: Comprehending 3d anomalies from points and pixels for zero-shot 3d anomaly detection. *arXiv preprint arXiv:2410.00320*, 2024.
- [10] Hongze Zhu, Guoyang Xie, Chengbin Hou, Tao Dai, Can Gao, Jinbao Wang, and Linlin Shen. Towards high-resolution 3d anomaly detection via group-level feature contrastive learning. In *Proceedings of the 32nd ACM International Conference on Multimedia*, pages 4680–4689, 2024.